

RAGstar : RAG 기반 On-Premises OOM 장애 진단 파이프라인

RAGstar : A RAG-Based On-Premises Pipeline for OOM Fault Diagnosis

강승묵°, 이규형, 박준영, 하지훈, 장두성 +
서강대학교 컴퓨터공학과, 인공지능학과



Abstract

RAGstar는 로컬 LLM과 ChromaDB를 결합한 **On-Premises OOM 장애 진단 RAG** 파이프라인이다. RAGstar가 사용한 구조화 쿼리는 원시 로그 대비 **Recall@3을 11.6배** 향상시켰다. RAGstar 로컬 모델 5종 모두 결정 규칙으로 **분류 정확도 1.000**을 달성하였으며, Qwen 3.5 9B를 RAGstar 파이프라인으로 전환하였을 때 **Evidence Recall은 13.0%, Action Guide Similarity는 19.2%** 향상되었다.

Introduction

기존 LLM 운영 로그 해석 시도의 한계

- ⊗ 클라우드 LLM : 인프라 내부 정보 유출 위험
- ⊗ LLM 단독 호출 : 관계 추론이 필요 시 실패

로컬 LLM + ChromaDB

On-Premises RAG 적용

swap exhaustion은 dmesg에 swap 키워드가 등장하더라도 swap usage = limit 관계 추론 필요

Swap Exhaustion:

Naive 0/5 → **RAGstar 5/5**

Tech Stack

LangGraph

기반 RAG 엔진

ChromaDB

벡터 유사도 검색 담당

vLLM

LLM 추론 담당

Ollama

임베딩 전용 (nomic-embed-text)


실험 1 : 검색 품질 평가

동일 ChromaDB 데이터에서 Raw 모드는 OOM 로그 원문을 그대로 쿼리로 사용하고, Structured 모드는 Node 1 파서가 추출한 핵심 필드에 정답 OOM 유형 토큰을 결합하여 토큰을 동적으로 구성한다. 평가는 로그별 정답 KB 청크 3개 대비 상위 K개의 Recall@K로 측정하였다.

Query Mode	Recall@3	Recall@5
Raw	0.018	0.036
Structured (Ours)	0.208	0.321
배율	×11.6	×9.0

실험 2 : 생성 품질 및 시스템 비용

RAG 파이프라인이 단일 Naive LLM 호출 대비 진단 품질을 얼마나 개선하는지, 그 효과가 모델규모 및 종류(로컬/상용)에 따라 어떻게 달라지는지를 측정한다. 비교군은 상용 GPT 5.2 Naive, 로컬 Qwen 3.5 9B Naive, 로컬 모델 5종 RAGstar이다. 모든 RAGstar 모델은 동일 임베딩, 결정 규칙, KB를 공유한다. 평가 지표는 Category Match, Evidence Recall, Action Guide Similarity, 쿼리 당 평균 사용 VRAM 및 추론 시간이다. VRAM 단위는 GB, 추론 시간 단위는 초 이다.



Pipeline (Node 1-4)

Input: OOM 원시 로그 + 메타데이터

로그 파싱

정규식 및 보조 정규식 Fallback

OOM 분류 · 도구 선정

결정 규칙 OOM 분류 → LLM 추론

도구 실행 · 검색

3가지 도구 실행, 메타필터 KB 검색

종합 진단

LLM 응답 생성, JSON 스키마 검증

Output: 원인 진단, 조치 가이드

Test Cases

OOM 유형	재현	합성	합계
cgroup_oom	30	0	30
global_oom	12	0	12
page_alloc_failure	0	9	9
swap_exhaustion	5	0	5
합계	47	9	56

Conclusion

RAGstar는 LLM 추론, 임베딩, 벡터 검색의 전 구성요소가 **외부 API 없이 폐쇄망**에서 동작하여 인프라 내부 정보 노출 없이 LLM 기반 OOM 장애 진단을 가능하게 한다. 따라서 **국방, 금융, 공공기관** 등 망 분리 환경에서의 적용성이 높다. 권장 구성인 Qwen 3.5 9B RAGstar 파이프라인은 GPT 5.2 Naive와 **생성 품질이 동등** 수준이면서 폐쇄망에서 동작한다. 또한 결정 규칙이 분류를 직접 산출하므로 **적은 VRAM의 소형 로컬 모델**만으로도 9B 모델과 동일한 분류 정확도를 확보하여 진입 장벽을 낮추며, **근본 원인, 근거, 조치 가이드**를 자동 생성하여 관리자의 로그 해석 부담을 경감한다. 또한 **메타데이터 기반 KB 구조**는 타 장애 유형이나 cgroup v2 신규 패턴으로 확장할 수 있다.