

RAGstar: Agentic RAG 기반 사내망 전용 OOM 디버깅 지원 웹 서비스

캡스톤디자인 1 | Track 2 자유주제 | 지도교수: 장두성

1. 목표

Linux 시스템의 Out-of-Memory(OOM) 장애는 해당 시스템 기반의 여러 통합 서비스 중단의 핵심 원인이지만, 수백 줄의 비정형 커널 로그 해석은 숙련된 관리자에게도 부담입니다. 또한 클라우드 LLM은 프로세스명, cgroup 경로, 커널 버전 등 인프라 내부 정보가 외부망과의 통신 과정에서 유출될 위험이 있기 때문에 폐쇄망 환경에 부적합합니다.

본 과제는 로컬 LLM과 RAG(Retrieval-Augmented Generation)를 정형적으로 결합한 사내망 전용 OOM 자동 진단 웹 서비스를 구축하여, 신입 개발자도 OOM 로그를 입력하면 근본 원인과 조치 가이드를 자동으로 받을 수 있도록 하는 것을 목표로 합니다.

해결하려는 기존 기술의 한계

- **OOM 예방 도구:** 프로세스를 사전에 종료하여 장애를 막을 수는 있지만, 사후에 왜 OOM이 발생했는지 자연어로 원인을 설명하지 못합니다.
- **이벤트 추적 및 크래시 덤프 도구:** 상세한 시스템 데이터를 수집할 수 있으나, 이를 해석하기 위해서는 전문 엔지니어의 수동 분석이 전적으로 필요합니다.
- **LLM 기반 인시던트 진단:** 대부분 호스팅 기반의 외부 상용 LLM을 전제로 하므로 사내 폐쇄망 환경에 적용이 불가능합니다. 폐쇄망 환경을 고려한 일부 최신 연구조차 로그 압축 및 토큰 감축에만 집중할 뿐, 외부 지식 베이스를 활용하거나 특정 장애 유형에 특화되어 있지 않습니다.
- **기존 RAG 기반 로그 분석:** 시퀀스 예측을 통한 단순 이상 탐지 여부 판정에 목표를 두고 있어, 커널 문서나 운영자 가이드에 근거한 구체적인 해결 조치 가이드를 생성하지는 못합니다.

RAGstar는 기존 기술의 공백을 메워 (i) 폐쇄망에서 로컬 LLM으로 안전하게 동작하고, (ii) 커널 OOM 장애 유형에 특화되며, (iii) 지식 베이스(KB)를 회상해 실질적인 조치 가이드를 생성하고, (iv) LangGraph를 통해 결정 규칙과 LLM의 판단을 유기적으로 결합합니다.

2. 범위

대상 장애 유형

- global_oom — 시스템 전체 메모리 부족
- cgroup_oom — 컨테이너 메모리 limit 초과
- swap_exhaustion — Swap 전부 소진
- page_alloc_failure — 높은 order 페이지 할당 실패

과제 상세 범위

본 과제의 평가 데이터셋은 56개의 OOM 로그와 Linux 커널 공식 문서, 운영체제 벤더 KB, 컨테이너 가이드 등을 기반으로 구축된 198개의 지식 베이스(KB) 청크로 구성됩니다. 각 로그에는 대응되는 정답 지식 베이스가 명확히 존재하며, 이는 카테고리(category), 증거(evidence), 조치 가이드(action_guide) 형태의 Ground Truth로 관리됩니다. 해당 시스템은 사내 폐쇄망 내의 웹 서비스 환경에서 운영되는 것을 전제로 하며, 최종 결과물로는 LangGraph 기반의 RAG 엔진, Streamlit 기반의 웹 UI, FastAPI 서버, 그리고 사용자 질의 및 진단 이력을 기록하는 DB가 산출됩니다.

3. 특징점

1. **4단계 LangGraph 파이프라인:** 로그 파싱(정규식) → OOM 유형 분류 및 도구 선정(LLM) → 도구 실행 및 KB 검색(코드 + 벡터 검색) → 종합 진단(LLM)의 단계로 분해하여 소형 로컬 LLM의 추론 부담을 완화하고 독립적 검증이 가능합니다.
2. **구조화 쿼리 기반 KB 검색:** 원시 로그 전체를 임베딩하지 않고, 추출된 23개 구조화 필드와 OOM 유형 정보를 결합해 동적으로 쿼리를 구성하여 노이즈 텍스트를 제거하고 검색 정밀도를 높입니다.
3. **운영 스택 최적화:** 기본 로컬 LLM으로 Qwen 3.5-9B를 채택하고, vLLM 서빙 엔진의 PagedAttention 및 연속 배칭 기술을 적용해 단일 로그 기준 16초 내외의 빠른 응답 시간을 확보했습니다.
4. **사내망 전용 웹 서비스:** Streamlit 기반 웹 UI를 통해 서버 및 서비스 메타데이터를 함께 입력받아 정확도를 향상시키며, 진단 결과를 DB에 축적하여 사내 지식 자산으로 활용합니다.

4. 수행결과

실험 1 — 검색 품질 평가

동일한 ChromaDB 컬렉션(KB 청크 198개) 환경에서 원시 로그 쿼리(Raw)와 구조화

쿼리(Structured)의 검색 성능(Recall@K)을 비교 평가했습니다.

$Recall@K = (\text{상위 } K\text{개 검색 결과 내 정답 문서 수}) / (\text{전체 정답 문서 수})$

평가 지표	원시 로그 쿼리 (Raw)	구조화 쿼리 (Structured)	성능 향상 비율
Recall@3	0.018	0.208	11.6배 향상
Recall@5	0.036	0.321	9.0배 향상


RAGstar를 적용한 결과 원시 로그에 포함된 타임스탬프, 메모리 주소, 프로세스 테이블 등의 노이즈 텍스트를 제거하고, 추출된 23개의 구조화 필드와 OOM 유형 정보를 결합해 동적으로 쿼리를 구성함으로써 검색 정밀도와 재현율을 대폭 개선할 수 있음을 정량적으로 검증하였습니다.

실험 2 — 생성 품질 평가

Qwen 3.5-9B와 GPT-5.2를 베이스라인으로 설정하고, RAGstar를 적용한 다양한 경량 로컬 LLM 모델들에 대해 정량 비교 평가를 진행했습니다. 쿼리당 평균 VRAM 사용량과 추론 시간을 함께 측정하여 폐쇄망 환경 내 경량 모델의 활용 가능성을 검증했습니다.

모델	유형 분류 일치도	평가 근거 재현율	추천 조치 유사도	평균 VRAM 사용량 (GB/Query)	평균 추론 시간 (Sec/Query)
Gemma4-E2B (RAG)	1.000	0.608	0.626	16.92	39.88
Gemma4-E4B (RAG)	1.000	0.585	0.637	39.64	56.13
Qwen3.5-0.8B (RAG)	1.000	0.588	0.566	17.15	123.33

모델	유형 분류 일치도	평가 근거 재현율	추천 조치 유사도	평균 VRAM 사용량 (GB/Query)	평균 추론 시간 (Sec/Query)
Qwen3.5-2B (RAG)	1.000	0.608	0.602	17.73	86.96
Qwen3.5-9B (RAG)	1.000	0.635	0.657	42.70	65.28
Qwen3.5-9B (Naive)	0.679	0.562	0.551	42.60	164.45
gpt-5.2 (Naive)	0.643	0.645	0.654	N/A	9.50



RAGstar를 적용한 결과 모델 체급에 무관하게 모든 분야에서 정량적 성능 지표가 크게 향상되었습니다. 특히 2B 등급의 초경량 모델의 경우, 자원 소모량(VRAM 및 추론 시간)을 대폭 절감하면서도 RAG가 적용되지 않은 9B 모델 이상의 성능을 입증하여 폐쇄망 내 자원 효율적인 서비스 운영 가능성을 확인했습니다.

5. 산출물 및 핵심 기여

산출물 및 진행 현황

한국정보과학회 KCC 2026 학술발표대회 논문 투고 완료

사내망 전용 웹 서비스(Streamlit + 사용자 DB) 구현 완료

외부 상용 LLM(GPT-5.2) 대비 벤치마킹 완료

초경량 2B 모델(Qwen 3.5-2B, Gemma 4 E2B) 현장 적용 가능성 실험 진행 완료

핵심 기여

(i) 파싱·분류·도구 실행·종합 진단의 4단계 LangGraph 파이프라인 설계

(ii) 56개 OOM 로그와 198개 KB 청크, 각 OOM에 대한 정답 라벨로 구성된 평가 데이터셋 구축

(iii) 구조화 쿼리가 원시 로그 쿼리 대비 검색 품질을 큰 폭으로 개선함을 정량 검증

(iv) vLLM 기반 최적화 및 2B급 초경량 모델의 성공적인 도입을 통해, 인프라 제약이 있는 사내망 환경에서도 고성능의 실시간 OOM 진단 서비스가 가능함을 입증